

Descripción General del Proyecto

El presente proyecto tiene como objetivo implementar un modelo de segmentación semántica basado en la arquitectura DeepLabV3+ para la detección y cuantificación de regiones relevantes en imágenes correspondientes a celdas de flotación. En particular, se busca identificar y segmentar regiones asociadas a burbujas, espuma, borde e interior/exterior de la celda.

La motivación principal radica en explorar la viabilidad del uso de técnicas de visión artificial como base para la construcción de un indicador cuantitativo de proceso, definido como el porcentaje de burbujas presentes en la imagen, con potencial integración futura en sistemas de monitoreo industrial.

Objetivos

- Implementar un modelo de segmentación semántica para imágenes de celdas de flotación.
- Detectar y clasificar regiones de interés (burbuja, espuma, borde, exterior).
- Calcular métricas cuantitativas de desempeño (IoU y Dice Similarity Coefficient).
- Definir un indicador de proceso basado en el porcentaje de burbujas en la imagen.
- Evaluar la estabilidad del indicador en secuencias de imágenes (análisis temporal).
- Proponer una arquitectura futura de integración con sistemas de control industrial (DCS).

Fundamentación Matemática del Modelo

El modelo implementado se basa en Redes Neuronales Convolucionales (CNN), las cuales utilizan operadores de convolución para extraer características espaciales relevantes de una imagen.

Sea $I(x, y)$ una imagen digital, la operación de convolución discreta puede representarse como:

$$(I * K)(x, y) = \sum_i \sum_j I(x - i, y - j)K(i, j)$$

donde K representa el kernel o filtro convolucional. La red aprende automáticamente los pesos de estos filtros mediante optimización basada en descenso por gradiente y retropropagación.

En segmentación semántica, el objetivo es aprender una función:

$$f_\theta : \mathbb{R}^{H \times W \times C} \rightarrow \{0, 1, 2, 3\}^{H \times W}$$

que asigne una etiqueta a cada píxel de la imagen.

Arquitectura DeepLabV3+

DeepLabV3+ incorpora:

- Backbone profundo (ej. ResNet-50) para extracción de características.

- Convoluciones dilatadas (atrous convolution) para ampliar el campo receptivo sin perder resolución.
- Módulo Atrous Spatial Pyramid Pooling (ASPP) para capturar información multiescala.
- Decoder para refinamiento espacial y recuperación de detalles finos.

Esta arquitectura resulta especialmente adecuada para segmentar estructuras irregulares y de contorno difuso como espuma y burbujas.

Herramientas Utilizadas

- Python 3.x
- PyTorch (entrenamiento y modelo DeepLabV3+)
- Torchvision
- OpenCV (lectura y procesamiento de imágenes)
- NumPy (operaciones matriciales)
- Pillow (manejo básico de imágenes)
- Matplotlib (visualización de métricas)
- LabelMe (anotación manual de máscaras)

Métricas de Evaluación

Intersection over Union (IoU):

$$IoU = \frac{|A \cap B|}{|A \cup B|}$$

Dice Similarity Coefficient (DSC):

$$DSC = \frac{2|A \cap B|}{|A| + |B|}$$

Ambas métricas miden el grado de solapamiento entre la máscara real y la máscara predicha.

Serie Temporal del Indicador

El porcentaje de burbujas definido como:

$$\% \text{Burbujas} = \frac{\text{Píxeles clase burbuja}}{\text{Total píxeles imagen}} \times 100$$

puede analizarse como una serie temporal cuando se dispone de secuencias de imágenes. Esto permite estudiar estabilidad, variabilidad y posibles correlaciones con variables operacionales del proceso de flotación.

Resultados Esperados

Se espera que el modelo logre:

- Segmentación consistente bajo distintas condiciones de iluminación.
- Baja variabilidad del indicador frente a ruido visual.
- Concordancia adecuada entre porcentaje real y predicho.

Proyección Industrial

El indicador desarrollado podría integrarse como variable auxiliar en sistemas de monitoreo industrial (DCS), permitiendo:

- Supervisión visual automatizada del estado de la celda.
- Detección temprana de anomalías.
- Potencial uso como variable complementaria en esquemas de control.

Limitaciones

- Tamaño reducido del dataset en etapa inicial.
- Dependencia de anotación manual.
- Posible sobreajuste en conjuntos pequeños.
- Sensibilidad a variaciones extremas de iluminación.

Estado Actual del Proyecto

Actualmente el proyecto cuenta con:

- Pipeline completo de procesamiento, entrenamiento e inferencia.
- Cálculo automático de métricas por imagen.
- Generación del indicador porcentual de burbujas.
- Validación preliminar con conjuntos de datos reducidos.

El siguiente paso consiste en ampliar el dataset y realizar evaluación estadística más robusta.